

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC ĐIỆN LỰC
KHOA CÔNG NGHỆ THÔNG TIN



ĐẠI HỌC ĐIỆN LỰC
ELECTRIC POWER UNIVERSITY

BÁO CÁO CHUYÊN ĐỀ HỌC PHẦN
PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU

ĐỀ TÀI:

PHÂN TÍCH VÀ XỬ LÝ DỮ LIỆU KHÁCH HÀNG
VAY TÍN DỤNG

GIẢNG VIÊN HƯỚNG DẪN	: TS. VŨ VĂN ĐỊNH
SINH VIÊN THỰC HIỆN	: NGUYỄN VĂN TÚ NGUYỄN THỊ LIÊN MAI VĂN HOÀNG
NGÀNH	: CÔNG NGHỆ THÔNG TIN
CHUYÊN NGÀNH	: CÔNG NGHỆ PHẦN MỀM
LỚP HỌC PHẦN	: D17CNPM4
KHÓA	: 2022-2027

Hà Nội, tháng ... năm 2025

PHIẾU CHẤM ĐIỂM

Sinh viên thực hiện:

STT	Họ tên Mã sinh viên	Nội dung thực hiện	Điểm	Chữ ký
1	Nguyễn Văn Tú 22810310083			
2	Nguyễn Thị Liên 22810310123			
3	Mai Văn Hoàng 22810310128			

Giảng viên chấm :

Họ và tên Giảng viên	Chữ ký	Ghi chú
Giảng viên chấm 1 :		
Giảng viên chấm 2 :		

LỜI CẢM ƠN

Trong suốt quá trình thực hiện luận văn này, chúng em đã nhận được rất nhiều sự quan tâm, chỉ dẫn và hỗ trợ quý báu từ các thầy cô và nhà trường. Chúng em xin được bày tỏ lòng biết ơn sâu sắc đến những người đã đồng hành, tạo điều kiện và truyền cảm hứng cho em hoàn thành tốt đề tài nghiên cứu này.

Trước hết, chúng em xin chân thành cảm ơn Ban Giám hiệu Trường Đại học Điện lực và Ban lãnh đạo Khoa Công nghệ thông tin đã tạo ra một môi trường học tập và nghiên cứu chuyên nghiệp, hiện đại và đầy cảm hứng. Sự quan tâm, định hướng của nhà trường và Khoa chính là nền tảng vững chắc để chúng em có thể phát triển tư duy, nâng cao kiến thức và từng bước tiến gần hơn đến con đường nghiên cứu khoa học.

Đặc biệt, chúng em xin gửi lời cảm ơn trân thành đến TS. Vũ Văn Định – giảng viên Khoa Công nghệ Thông tin, người đã trực tiếp hướng dẫn em trong suốt quá trình thực hiện đề tài. Với sự tận tụy, nghiêm túc và luôn sẵn sàng hỗ trợ, cô đã giúp em tiếp cận phương pháp nghiên cứu một cách khoa học và hiệu quả. Những kiến thức quý giá và sự chỉ bảo tận tình của thầy không chỉ giúp chúng em hoàn thành tốt đề tài này mà còn là hành trang quý báu trên con đường tương lai sau này.

Trân trọng!

MỤC LỤC

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT	
DANH MỤC CÁC HÌNH ẢNH, ĐỒ THỊ.....	
DANH MỤC CÁC BẢNG	
LỜI MỞ ĐẦU	1
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	2
1.1. Thực trạng hiện tại	2
1.1.1. Bối cảnh kinh tế	2
1.1.2. Tài Chính và Ngành Ngân Hàng.....	2
1.1.3. Thách thức trong Kỷ nguyên Dữ liệu lớn (Big Data)	3
1.1.4. Tác động của Dự đoán Rủi ro Tín dụng.....	3
1.2. Giới thiệu về đề tài	4
1.3. Mục Tiêu Nghiên Cứu.....	5
CHƯƠNG 2. NỘI DUNG VÀ PHƯƠNG PHÁP NGHIÊN CỨU	7
2.1 Đối tượng và phạm vi nghiên cứu.....	7
2.1.1. Đối tượng nghiên cứu.....	7
2.1.2. Phạm vi nghiên cứu.....	7
2.2 Nội dung nghiên cứu	8
2.2.1. Thuật toán Random Forest	8
2.2.2. Các chỉ số đánh giá	10
2.2.3. Dataset Default of Credit Card Clients	11
2.3. Phân tích dữ liệu (EDA).....	16
2.3.1. Phân tích Dữ liệu thiếu (Missing values):.....	16
2.3.2. Phân bố biến mục tiêu:	17
2.3.3. Phân tích phân bố các biến chính:.....	18
2.3.4. Phân tích mối tương quan giữa các biến:	19
2.3.5. Mối quan hệ giữa các biến và mục tiêu dự đoán:	20
2.4. Đánh Giá Mô Hình Baseline	21

CHƯƠNG 3. XỬ LÝ VÀ CHẠY MÔ HÌNH.....	24
3.1. Xử lý dữ liệu.....	24
3.1.1. Xử lý dữ liệu âm.....	24
3.1.2. Xử lý dữ liệu thiếu (Missing values).....	24
3.1.3. Xử lý Outliers.....	24
3.1.4. Chia và cân bằng dữ liệu.....	25
3.1.5. Chuẩn hóa dữ liệu	25
3.2. Chạy và đánh giá mô hình sau xử lý	25
3.2.1. Huấn luyện mô hình.....	25
3.2.2. Đánh giá mô hình (ngưỡng threshold = 0.5).....	27
3.2.3. Đánh giá mô hình (ngưỡng tối ưu).....	28
3.3. Phân tích và so sánh (base và opti)	30
3.4. Trực quan hóa.....	32
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	40
DANH MỤC TÀI LIỆU THAM KHẢO	43

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT

STT	Từ viết tắt	Mô tả
1	UCI	University of California, Irvine (Đại học California, Irvine)
2	EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
3	SMOTE	Synthetic Minority Over-sampling Technique (Kỹ thuật tăng cường mẫu thiểu số)
4	KNN	K-Nearest Neighbors (Thuật toán K láng giềng gần nhất)
5	IQR	Interquartile Range (Phạm vi giữa các phân vị thứ nhất và thứ ba)
6	RF	Random Forest (Rừng quyết định ngẫu nhiên)
7	AUC	Area Under the Curve (Diện tích dưới đường cong, thường dùng trong AUC-ROC)
8	ROC	Receiver Operating Characteristic (Đặc tính nhận dạng người nhận)
9	TP	True Positive (Dự đoán đúng của lớp dương)
10	TN	True Negative (Dự đoán đúng của lớp âm)
11	FP	False Positive (Dự đoán sai của lớp dương)
12	FN	False Negative (Dự đoán sai của lớp âm)
13	F1-score	Điểm F1 (Trung bình điều hòa của Precision và Recall)
14	Precision	Độ chính xác âm (Tỷ lệ dự đoán dương đúng so với tổng số dự đoán dương)
15	Recall	Độ thu hồi (Tỷ lệ phát hiện đúng các mẫu dương trong tổng số mẫu dương thực tế)
16	Accuracy	Độ chính xác (Tỷ lệ các dự đoán đúng trên tổng số mẫu)
17	Class Imbalance	Mất cân bằng lớp (Khi một lớp có số lượng mẫu lớn hơn nhiều so với lớp còn lại)

DANH MỤC CÁC HÌNH ẢNH, ĐỒ THỊ

Hình 2.1 Logo của University of California, Irvine.....	11
Hình 2.2. Nội dung của tập dữ liệu	13
Hình 2.3 Dữ liệu thiếu.....	16
Hình 2.4 Phân bố biến mục tiêu.....	17
Hình 2.5 Phân bố các biến chính - numeric	18
Hình 2.6 Heatmap tương quan giữa các đặc trưng	19
Hình 2.7 Biểu đồ tương quan giữa các biến và mục tiêu dự đoán.....	20
Hình 2.8 Kết quả chạy mô hình baseline	22
Hình 2.9 Trực quan hóa kết quả mô hình baseline.....	23
Hình 3.1 Lựa chọn tham số	26
Hình 3.2 Kết quả đánh giá mô hình với threshold = 0.5.....	27
Hình 3.3 Kết quả đánh giá với threshold sau khi tối ưu	28
Hình 3.4 Biểu đồ so sánh kết quả hai mô hình	31
Hình 3.5 Các đặc trưng quan trọng	32
Hình 3.6 ROC Curve và Precision-Recall Curve với Threshold tối ưu.....	33
Hình 3.7 Ma trận nhầm lẫn.....	35
Hình 3.8 Biểu Đồ Phân Tích Xác Suất Dự Đoán và Ngưỡng Quyết Định.....	36

DANH MỤC CÁC BẢNG

Bảng 2.1 Danh sách các thuộc tính của tập dữ liệu	13
Bảng 3.1 So sánh chỉ số của các mô hình	30

LỜI MỞ ĐẦU

Trong kỷ nguyên chuyển đổi số hiện nay, dữ liệu được xem là nguồn tài nguyên chiến lược, mang lại lợi thế cạnh tranh vượt trội cho các doanh nghiệp. Đặc biệt trong lĩnh vực tài chính – ngân hàng, hoạt động cho vay tín dụng luôn là nguồn thu nhập chủ yếu nhưng cũng là hoạt động tiềm ẩn rủi ro lớn nhất. Việc đối mặt với rủi ro tín dụng, tức là khả năng khách hàng không thể hoặc không muốn thực hiện nghĩa vụ trả nợ, đòi hỏi các tổ chức phải có phương pháp đánh giá và quản lý rủi ro một cách khoa học và chính xác. Do đó, việc phân tích và xử lý dữ liệu khách hàng vay tín dụng trở thành một nhiệm vụ cấp thiết để duy trì sự ổn định và phát triển bền vững của hệ thống tài chính.

Đề tài "Phân tích và xử lý dữ liệu khách hàng vay tín dụng" được lựa chọn nghiên cứu trong khuôn khổ môn học Phân tích và Trực quan hóa Dữ liệu nhằm giải quyết trực tiếp vấn đề quản lý rủi ro dựa trên dữ liệu. Mục tiêu chính của nghiên cứu này là áp dụng các kỹ thuật phân tích dữ liệu chuyên sâu để khám phá một số yếu tố ảnh hưởng đến khả năng vỡ nợ của khách hàng. Thông qua quá trình làm sạch, tiền xử lý và mô hình hóa dữ liệu, chúng tôi mong muốn xây dựng được một cái nhìn tổng quan, khách quan về hành vi của người vay.

Nghiên cứu sẽ tập trung vào việc áp dụng các công cụ và phương pháp phân tích dữ liệu tiên tiến, bao gồm thống kê mô tả, phân tích khám phá dữ liệu (EDA) và kỹ thuật trực quan hóa dữ liệu hiệu quả. Các biểu đồ và bảng tổng hợp trực quan được tạo ra sẽ giúp đơn giản hóa những thông tin phức tạp, chuyển đổi dữ liệu thô thành kiến thức có thể hành động được. Sản phẩm cuối cùng của đề tài không chỉ là báo cáo mang tính học thuật mà còn đề xuất các kiến nghị thực tiễn, giúp các tổ chức tài chính cải thiện quy trình thẩm định hồ sơ, tối ưu hóa danh mục cho vay và đưa ra các quyết định kinh doanh kịp thời dựa trên bằng chứng dữ liệu.

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1. Thực trạng hiện tại

1.1.1. Bối cảnh kinh tế

Trong những năm qua, các nền kinh tế toàn cầu đã phải đối mặt với nhiều thách thức, bao gồm khủng hoảng tài chính, lãi suất thấp kéo dài, và các biến động kinh tế vĩ mô do các yếu tố như dịch bệnh COVID-19. Những yếu tố này đã làm gia tăng rủi ro tín dụng, khi mà nhiều cá nhân, đặc biệt là những người có thu nhập thấp hoặc không ổn định, gặp khó khăn trong việc trả nợ. Ngành ngân hàng và các tổ chức tín dụng phải đối mặt với việc cân bằng giữa việc mở rộng cho vay và đảm bảo an toàn tài chính.

Bối cảnh này tạo ra nhu cầu lớn đối với các hệ thống phân tích và dự đoán rủi ro tín dụng, nhằm giúp giảm thiểu thiệt hại cho các tổ chức tài chính và giúp họ đưa ra các quyết định vay vốn chính xác hơn. Dữ liệu như *Default of Credit Card Clients* cung cấp thông tin về hành vi chi tiêu của khách hàng, từ đó dự đoán khả năng vỡ nợ và giúp ngân hàng quản lý danh mục tín dụng của mình tốt hơn.

1.1.2. Tài Chính và Ngành Ngân Hàng

Ngành ngân hàng đang phải đối mặt với những thay đổi lớn trong cách quản lý tín dụng và nợ xấu. Trước kia, việc xác định rủi ro tín dụng thường dựa vào thông tin thủ công và những tiêu chuẩn đơn giản như thu nhập và lịch sử tín dụng. Tuy nhiên, trong thời đại số hóa, các công cụ phân tích dữ liệu hiện đại, đặc biệt là học máy (machine learning), đã giúp các tổ chức tài chính xây dựng những mô hình dự đoán chính xác hơn về khả năng vỡ nợ của khách hàng.

Dữ liệu *Default of Credit Card Clients* là một ví dụ điển hình, cung cấp một bộ dữ liệu lớn về khách hàng sử dụng thẻ tín dụng tại Đài Loan. Bộ dữ liệu này chứa thông tin về các đặc điểm cá nhân của khách hàng, như tuổi, giới tính, tình trạng hôn nhân, số lượng các khoản vay, và lịch sử thanh toán của họ. Việc phân tích dữ liệu này giúp dự đoán xem liệu khách hàng có khả năng không thanh toán các khoản nợ thẻ tín dụng hay không.

1.1.3. Thách thức trong Kỷ nguyên Dữ liệu lớn (Big Data)

Các tổ chức tài chính hiện nay đang thu thập một khối lượng dữ liệu khổng lồ về khách hàng, không chỉ giới hạn ở thông tin tài chính truyền thống (thu nhập, lịch sử tín dụng) mà còn mở rộng sang dữ liệu hành vi giao dịch, tương tác số, và nhân khẩu học.

- **Tính cấp thiết 1:** Nhu cầu Dự báo Rủi ro Sớm: Các mô hình đánh giá tín dụng truyền thống (ví dụ: mô hình dựa trên điểm số Z-score hay các phương pháp định tính) thường không đủ nhạy bén để phát hiện các mẫu hình vỡ nợ phức tạp và phi tuyến tính. Cần có các mô hình dự báo sử dụng Học máy (Machine Learning) để tính toán Xác suất Vỡ nợ (Probability of Default - PD) một cách chính xác và sớm nhất có thể.
- **Tính cấp thiết 2:** Tối ưu hóa Chu trình Cho vay (Loan Cycle): Việc phân tích dữ liệu chuyên sâu giúp tổ chức tài chính không chỉ dừng lại ở việc ra quyết định chấp thuận hay từ chối khoản vay, mà còn hỗ trợ cá nhân hóa các quyết định khác như đặt hạn mức tín dụng, định giá lãi suất (Pricing) và quản lý nợ quá hạn.

1.1.4. Tác động của Dự đoán Rủi ro Tín dụng

Dự đoán rủi ro tín dụng không chỉ giúp ngân hàng giảm thiểu các khoản vay xấu mà còn hỗ trợ trong việc tối ưu hóa các chiến lược tín dụng. Ví dụ, các ngân hàng có thể áp dụng các biện pháp quản lý rủi ro phù hợp, chẳng hạn như tăng cường yêu cầu về tài sản thế chấp đối với những khách hàng có điểm tín dụng thấp hoặc giảm giới hạn tín dụng đối với những khách hàng có dấu hiệu không ổn định trong việc thanh toán.

Ngoài ra, việc sử dụng các mô hình dự đoán giúp cải thiện hiệu quả trong việc phân bổ tài nguyên của các tổ chức tài chính. Việc đánh giá chính xác mức độ rủi ro tín dụng giúp các ngân hàng đưa ra các quyết định chiến lược tốt hơn, chẳng hạn như quyết định nâng cao hoặc giảm lãi suất cho các khách hàng có mức độ rủi ro khác nhau.

1.2. Giới thiệu về đề tài

Trong kỷ nguyên công nghệ số hiện nay, ngành tài chính đang trải qua những biến đổi sâu rộng với sự bùng nổ của dữ liệu lớn (Big Data). Các tổ chức tài chính không chỉ thu thập các thông tin tài chính truyền thống như thu nhập, lịch sử tín dụng mà còn mở rộng ra những dữ liệu hành vi giao dịch, tương tác số, và đặc biệt là thông tin nhân khẩu học của khách hàng. Sự phát triển mạnh mẽ của công nghệ phân tích dữ liệu đã tạo ra những cơ hội lớn trong việc nâng cao khả năng ra quyết định và tối ưu hóa quy trình tài chính, từ việc cấp tín dụng đến quản lý rủi ro.

Một trong những thách thức lớn nhất hiện nay đối với các tổ chức tài chính là làm sao để dự báo và quản lý rủi ro tín dụng một cách chính xác và hiệu quả trong một môi trường với khối lượng dữ liệu ngày càng lớn. Các mô hình tín dụng truyền thống như điểm số Z-score hay phương pháp định tính đã không còn đủ mạnh để xử lý các mẫu hình vỡ nợ phức tạp và phi tuyến tính trong thời đại dữ liệu lớn. Chính vì vậy, nhu cầu ứng dụng các kỹ thuật học máy (Machine Learning) để dự đoán rủi ro tín dụng, tính toán Xác suất Vỡ nợ (Probability of Default - PD) ngày càng trở nên cấp thiết.

Đề tài này tập trung vào việc nghiên cứu và áp dụng các phương pháp học máy trong việc dự báo rủi ro tín dụng, nhằm nâng cao hiệu quả trong quá trình đánh giá và cấp tín dụng. Cụ thể, đề tài sẽ tìm hiểu về các mô hình phân tích dữ liệu, ứng dụng học máy để xác định xác suất vỡ nợ của khách hàng, từ đó giúp các tổ chức tài chính có thể đưa ra các quyết định tín dụng chính xác hơn và kịp thời.

Bên cạnh đó, việc tối ưu hóa chu trình cho vay cũng là một trong những yếu tố quan trọng mà đề tài này muốn làm rõ. Dữ liệu lớn không chỉ giúp tổ chức tài chính trong việc đánh giá và ra quyết định tín dụng, mà còn có thể hỗ trợ cá nhân hóa các quyết định khác như định giá lãi suất, hạn mức tín dụng và quản lý nợ quá hạn. Điều này giúp tối ưu hóa hiệu quả tài chính của tổ chức, đồng thời giảm thiểu các rủi ro liên quan đến việc cấp tín dụng.

Với mục tiêu làm rõ những lợi ích mà việc áp dụng các công nghệ phân tích dữ liệu và học máy có thể mang lại, đề tài sẽ đưa ra những giải pháp giúp các tổ chức tài chính không chỉ cải thiện quy trình đánh giá tín dụng mà còn tăng cường khả năng phát hiện sớm rủi ro và tối ưu hóa chiến lược cho vay, từ đó thúc đẩy sự phát triển bền vững của ngành tài chính trong thời đại số hóa.

1.3. Mục Tiêu Nghiên Cứu

Mục tiêu của đề tài này là nghiên cứu và áp dụng các phương pháp học máy (Machine Learning) trong việc dự báo rủi ro tín dụng và tối ưu hóa quy trình cho vay trong ngành tài chính. Đầu tiên, đề tài hướng đến xây dựng các mô hình học máy nhằm dự đoán Xác suất Vỡ nợ (Probability of Default - PD) của khách hàng dựa trên các yếu tố tài chính và hành vi giao dịch. Các mô hình này sẽ được so sánh với các phương pháp truyền thống như Logistic Regression, Decision Trees, Random Forest và Gradient Boosting Machines (GBM) để đánh giá hiệu quả của từng thuật toán trong việc dự báo rủi ro tín dụng. Bên cạnh đó, đề tài cũng sẽ nghiên cứu sự ảnh hưởng của các đặc điểm khách hàng như thu nhập, tuổi, tình trạng hôn nhân và hành vi giao dịch như lịch sử thanh toán và mức chi tiêu đến khả năng vỡ nợ.

Ngoài việc dự báo rủi ro tín dụng, đề tài còn tập trung vào việc tối ưu hóa chu trình cho vay. Phân tích dữ liệu từ các mô hình học máy không chỉ giúp các tổ chức tài chính trong việc ra quyết định chấp nhận hay từ chối khoản vay, mà còn hỗ trợ cá nhân hóa các quyết định khác như đặt hạn mức tín dụng, định giá lãi suất và quản lý nợ quá hạn. Đề tài sẽ đưa ra các chiến lược để tối ưu hóa các quyết định này nhằm giảm thiểu rủi ro và tối đa hóa lợi nhuận cho các tổ chức tài chính.

Một mục tiêu quan trọng khác của đề tài là đánh giá hiệu quả của các mô hình học máy trong việc dự báo rủi ro tín dụng, so với các phương pháp truyền thống. Các chỉ số đánh giá như độ chính xác (accuracy), độ dự đoán (precision), độ bao phủ (recall) điểm F1 (F1-score) và AUC-ROC sẽ được sử dụng để so sánh mức độ hiệu quả của các mô hình. Đề tài cũng sẽ kiểm tra sự cải thiện của các mô hình học máy trong việc phát hiện rủi ro tín dụng so với các phương pháp đánh

giá truyền thông, và phân tích các yếu tố ảnh hưởng đến hiệu quả của mô hình như chất lượng dữ liệu và khả năng xử lý các mẫu hình phi tuyến tính.

Cuối cùng, đề tài sẽ cung cấp các giải pháp thực tiễn giúp các tổ chức tài chính ứng dụng các mô hình học máy trong việc xây dựng các công cụ hỗ trợ ra quyết định tín dụng tự động. Các giải pháp này không chỉ giúp tiết kiệm thời gian và giảm thiểu sai sót trong quy trình xét duyệt hồ sơ vay mà còn khuyến khích sự chuyển đổi số trong ngành tài chính. Đề tài cũng sẽ nghiên cứu các vấn đề liên quan đến bảo mật và quyền riêng tư khi sử dụng dữ liệu khách hàng trong các mô hình học máy, nhằm đảm bảo tuân thủ các quy định về bảo vệ dữ liệu cá nhân.

Thông qua việc thực hiện các mục tiêu này, đề tài sẽ giúp các tổ chức tài chính không chỉ cải thiện quy trình quản lý rủi ro tín dụng mà còn tối ưu hóa các quyết định tín dụng, từ đó nâng cao hiệu quả tài chính và giảm thiểu các tổn thất từ các khoản vay xấu, đồng thời thúc đẩy ngành tài chính phát triển bền vững trong kỷ nguyên số.

CHƯƠNG 2. NỘI DUNG VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1 Đối tượng và phạm vi nghiên cứu.

2.1.1. Đối tượng nghiên cứu

Tập dữ liệu Default of Credit Card Clients: Đây là đối tượng chính trong bài nghiên cứu, được lựa chọn từ UCI Machine Learning Repository. Tập dữ liệu gồm có 23 đặc trưng thuộc tính bao gồm các yếu tố nhân khẩu học, tài chính và hành vi giao dịch, qua đó giúp chúng ta phân tích và dự đoán khả năng vỡ nợ của khách hàng

Thuật toán Random Forest: Đề tài sẽ tập trung vào việc áp dụng thuật toán Random Forest để xử lý hiệu quả các đặc trưng phức tạp, giảm thiểu overfitting, cung cấp độ chính xác cao, và giúp hiểu rõ các yếu tố quan trọng ảnh hưởng đến rủi ro tín dụng.

2.1.2. Phạm vi nghiên cứu

- Phân tích bộ dữ liệu Default of Credit Card Clients:

- + Tìm hiểu cấu trúc, các thuộc tính và đặc điểm trong bộ dữ liệu từ đó tìm kiếm và lựa chọn những đặc điểm, thuộc tính nổi bật
- + Tập trung vào phân tích đặc điểm của các đặc tính nổi bật

- Tiền xử lý dữ liệu:

- + Xử lý các vấn đề về chất lượng dữ liệu như loại bỏ bản ghi trùng, xử lý giá trị thiếu, và mã hóa các thuộc tính dạng chuỗi sang dạng số để phù hợp với thuật toán học máy Random Forest.
- + Chuẩn hóa hoặc chuyển đổi dữ liệu nếu cần thiết để đảm bảo tính nhất quán và phù hợp với mô hình Random Forest.

- Nghiên cứu và áp dụng các phương pháp xử lý, lựa chọn ra những thuộc tính nổi bật, ảnh hưởng tới khả năng vỡ nợ của khách hàng.

- Đánh giá kết quả đạt được:

- + Đánh giá kết quả mô hình với tập dữ liệu trước khi xử lý (dữ liệu nguyên bản của bộ dữ liệu) và tập dữ liệu sau khi được xử lý

- + Tìm kiếm, đưa ra những thuộc tính ảnh hưởng mạnh tới khả năng vỡ nợ của khách hàng

2.2 Nội dung nghiên cứu

2.2.1. Thuật toán Random Forest

Random Forest là một thuật toán học máy mạnh mẽ và phổ biến trong các bài toán phân loại và hồi quy. Đây là một phương pháp học máy dựa trên việc kết hợp nhiều cây quyết định (Decision Trees) để tạo thành một mô hình dự đoán mạnh mẽ hơn, từ đó giảm thiểu được hiện tượng overfitting (quá khớp) mà các cây quyết định đơn lẻ dễ mắc phải.

- Cấu Trúc và Nguyên Tắc Hoạt Động

Random Forest là một thuật toán thuộc nhóm phương pháp ensemble learning, trong đó ensemble có nghĩa là "kết hợp nhiều mô hình con để đưa ra kết quả tổng thể". Cụ thể, Random Forest xây dựng một tập hợp các cây quyết định độc lập và kết hợp kết quả của tất cả các cây này lại để đưa ra dự đoán chung. Cơ chế hoạt động của Random Forest bao gồm hai bước chính:

- **Bootstrap Aggregating (Bagging):** Để xây dựng mỗi cây quyết định, Random Forest sử dụng phương pháp bootstrap để tạo ra các bộ dữ liệu con khác nhau từ bộ dữ liệu gốc. Mỗi cây trong rừng được huấn luyện trên một bộ dữ liệu con khác nhau, điều này giúp tăng tính đa dạng của các cây và giảm thiểu sự tương quan giữa chúng.
- **Random Feature Selection:** Mỗi cây quyết định trong Random Forest chỉ sử dụng một tập hợp con ngẫu nhiên của các đặc trưng (features) trong quá trình xây dựng, thay vì sử dụng tất cả các đặc trưng. Điều này giúp tạo ra sự đa dạng giữa các cây và giảm thiểu overfitting.

- Quy Trình Hoạt Động

Quy trình xây dựng và dự đoán của Random Forest có thể tóm tắt qua các bước sau:

- Bước 1: Tạo ra nhiều mẫu con từ bộ dữ liệu gốc bằng phương pháp bootstrap (chọn ngẫu nhiên các điểm dữ liệu với khả năng lặp lại).

- Bước 2: Xây dựng một cây quyết định cho mỗi mẫu con, nhưng trong mỗi nút phân chia của cây, chỉ sử dụng một tập hợp con ngẫu nhiên của các đặc trưng.
- Bước 3: Khi dự đoán, mỗi cây trong rừng sẽ đưa ra một dự đoán (trong bài toán phân loại, dự đoán của mỗi cây là một lớp; trong bài toán hồi quy, dự đoán là một giá trị số). Kết quả cuối cùng của Random Forest sẽ là:
 - Trong bài toán phân loại: kết quả dự đoán được chọn là lớp được dự đoán nhiều nhất từ tất cả các cây (voting).
 - Trong bài toán hồi quy: kết quả dự đoán là giá trị trung bình của các kết quả dự đoán từ tất cả các cây.
- **Ưu Điểm của Random Forest**
 - Độ chính xác cao: Random Forest thường có độ chính xác rất cao trong các bài toán phân loại và hồi quy, nhờ vào việc kết hợp nhiều cây quyết định.
 - Chống overfitting: Vì Random Forest sử dụng nhiều cây và sử dụng các mẫu con khác nhau, nó giúp giảm thiểu hiện tượng overfitting mà các cây quyết định đơn lẻ có thể gặp phải.
 - Khả năng xử lý dữ liệu thiếu: Random Forest có thể xử lý dữ liệu thiếu khá tốt, vì mỗi cây quyết định trong rừng có thể sử dụng các mẫu con khác nhau, và do đó, không phụ thuộc vào dữ liệu hoàn chỉnh.
 - Khả năng làm việc với dữ liệu phức tạp: Random Forest có thể xử lý dữ liệu với nhiều đặc trưng và quan hệ phi tuyến tính mà các phương pháp học máy khác có thể gặp khó khăn.
- **Nhược Điểm của Random Forest**
 - Tính giải thích thấp: Một trong những nhược điểm lớn của Random Forest là khả năng giải thích kết quả thấp. Do việc sử dụng nhiều cây quyết định, khó có thể biết chính xác cây nào ảnh hưởng lớn đến quyết định cuối cùng.
 - Tốn tài nguyên tính toán: Việc xây dựng và duy trì nhiều cây quyết định đòi hỏi tài nguyên tính toán lớn, đặc biệt là khi dữ liệu có kích thước lớn hoặc số lượng cây trong rừng nhiều.

- Không hoạt động tốt với dữ liệu có mối quan hệ giữa các đặc trưng: Mặc dù Random Forest có thể xử lý dữ liệu phức tạp, nhưng nếu dữ liệu có mối quan hệ phức tạp và đặc trưng có sự phụ thuộc mạnh mẽ, mô hình này có thể không hoạt động tốt như các mô hình khác như Gradient Boosting hay XGBoost.

2.2.2. Các chỉ số đánh giá

- Accuracy (Độ chính xác)

- **Định nghĩa:** Accuracy là tỷ lệ phần trăm số dự đoán đúng trên tổng số mẫu. Nó được tính bằng công thức:

$$\text{Accuracy} = \frac{\text{Số dự đoán đúng}}{\text{Tổng số mẫu}}$$

- **Ý nghĩa:** Accuracy đo lường mức độ chính xác tổng thể của mô hình, tức là khả năng mô hình dự đoán đúng tất cả các mẫu. Tuy nhiên, trong các bài toán mất cân bằng (ví dụ, khi một lớp chiếm ưu thế rõ rệt), accuracy có thể không phản ánh đúng chất lượng mô hình.

- Precision (Độ chính xác âm)

- **Định nghĩa:** Precision đo lường tỷ lệ các dự đoán dương (positive) đúng so với tổng số dự đoán dương của mô hình. Nó được tính bằng công thức:

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Ý nghĩa:** Precision phản ánh khả năng mô hình không đưa ra dự đoán sai (false positive) khi dự đoán một lớp là dương. Đây là chỉ số quan trọng trong các bài toán yêu cầu ít sai sót khi mô hình dự đoán dương (ví dụ: trong y tế hoặc tài chính).

- Recall (Độ thu hồi)

- **Định nghĩa:** Recall đo lường tỷ lệ các mẫu dương được mô hình phát hiện ra so với tổng số mẫu dương thực tế. Nó được tính bằng công thức:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **Ý nghĩa:** Recall cho thấy khả năng của mô hình trong việc phát hiện tất cả các mẫu thuộc lớp dương. Đối với các bài toán mà việc bỏ sót một dự đoán dương (false negative) là nghiêm trọng, recall là một chỉ số quan trọng..

- F1-score (Điểm F1)

- **Định nghĩa:** F1-score là trung bình điều hòa của precision và recall, giúp cân bằng giữa độ chính xác và độ thu hồi. Nó được tính bằng công thức:

$$F1\text{-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Ý nghĩa:** F1-score kết hợp cả precision và recall vào một chỉ số duy nhất và đặc biệt hữu ích khi cần đánh giá mô hình trong các bài toán mất cân bằng, khi mà chỉ có một chỉ số đơn lẻ có thể không phản ánh đầy đủ hiệu quả của mô hình.

- AUC-ROC (Diện tích dưới đường cong ROC)

- **Định nghĩa:** AUC-ROC đo lường khả năng phân biệt giữa các lớp dương và âm của mô hình. ROC (Receiver Operating Characteristic) là đồ thị biểu diễn tỷ lệ false positive rate (FPR) và true positive rate (TPR) ở các ngưỡng khác nhau, và AUC là diện tích dưới đường cong ROC. AUC có giá trị từ 0 đến 1, với 1 là mô hình hoàn hảo và 0.5 là mô hình ngẫu nhiên.
- **Ý nghĩa:** AUC-ROC cho thấy khả năng của mô hình trong việc phân biệt chính xác các lớp. Mô hình với AUC gần 1 sẽ có khả năng phân loại rất tốt, trong khi AUC gần 0.5 cho thấy mô hình gần như không có khả năng phân biệt giữa các lớp.

2.2.3. Dataset Default of Credit Card Clients

2.2.3.1. Giới thiệu về bộ dữ liệu



Hình 2.1 Logo của University of California, Irvine

UCI Machine Learning Repository, một kho lưu trữ dữ liệu nổi tiếng được phát triển và duy trì bởi University of California, Irvine (UCI). UCI Machine Learning Repository là một trong những nguồn tài nguyên lớn nhất cho các bộ dữ liệu được sử dụng trong nghiên cứu và thực hành học máy (machine learning), cung cấp hàng nghìn bộ dữ liệu với đa dạng chủ đề, từ y tế, tài chính, đến sinh học và kỹ thuật.

- UCI Machine Learning Repository cung cấp các bộ dữ liệu mà các nhà nghiên cứu, học giả, và chuyên gia trong lĩnh vực học máy có thể sử dụng để thử nghiệm các mô hình học máy và thuật toán khác nhau.
- Kho lưu trữ này không chỉ cung cấp các bộ dữ liệu mà còn cung cấp các thông tin mô tả chi tiết về bộ dữ liệu, bao gồm mục tiêu nghiên cứu, các thuộc tính của bộ dữ liệu, cách sử dụng và các tham chiếu nghiên cứu nếu có.
- Dữ liệu trong kho này được phân loại theo nhiều lĩnh vực khác nhau, giúp người dùng dễ dàng tìm kiếm và tải về bộ dữ liệu phù hợp cho nghiên cứu của mình.

Bộ dữ liệu này được thu thập từ **Taiwan's Credit Card Clients** và được cung cấp bởi **UCI Machine Learning Repository** cho cộng đồng nghiên cứu và học tập. Bộ dữ liệu này đã được sử dụng rộng rãi trong các nghiên cứu về phân tích rủi ro tín dụng và các thuật toán học máy, đặc biệt là trong các bài toán phân loại (classification) và hồi quy (regression).

- **Nguồn cung cấp:** **Taiwan's Credit Card Clients**, đã được xử lý và cung cấp cho cộng đồng học máy qua kho lưu trữ của UCI.
- **Mục đích:** Bộ dữ liệu này chủ yếu dùng để nghiên cứu và phát triển các mô hình học máy nhằm dự đoán khả năng vỡ nợ của khách hàng dựa trên các đặc trưng tài chính và hành vi thanh toán.

2.2.3.2. Bộ dữ liệu Default of Credit Card Clients

Bộ dữ liệu **"Default of Credit Card Clients"** là một bộ dữ liệu được sử dụng để dự đoán rủi ro tín dụng, bao gồm thông tin về các khách hàng sử dụng

thẻ tín dụng tại một ngân hàng. Bộ dữ liệu này chủ yếu được dùng trong các bài toán phân loại (classification) với mục tiêu dự đoán khả năng vỡ nợ của khách hàng.

Nội dung bộ dữ liệu:

- **Biến mục tiêu (target variable): Default payment next month** — Liệu khách hàng có vỡ nợ trong tháng tới hay không (1 = vỡ nợ, 0 = không vỡ nợ).
- **Các đặc trưng (features):** Bộ dữ liệu bao gồm các thông tin về lịch sử tín dụng của khách hàng, số dư tín dụng, các khoản thanh toán trước đó, số tiền nợ, thu nhập, giới tính, tuổi, tình trạng hôn nhân, và các yếu tố khác có ảnh hưởng đến khả năng trả nợ.
- Bộ dữ liệu chứa 23 thuộc tính, trong đó các thuộc tính chủ yếu là số liệu và có một vài thuộc tính dạng chuỗi, và bộ dữ liệu có tổng cộng 30.000 bản ghi

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	
1	ID	LIMIT_BAL	SEX	EDUCATION	MARRIAGE	AGE	PAY_1	PAY_2	PAY_3	PAY_4	PAY_5	PAY_6	BILL_AMT1	BILL_AMT2	BILL_AMT3	BILL_AMT4	BILL_AMT5	BILL_AMT6	PAY_AMT1	PAY_AMT2	PAY_AMT3	PAY_AMT4	PAY_AMT5	PAY_AMT6	defaultpayment	
2	1		2	2	1		2			-1		-2	3913	3102	689	0	6109.91	0	689		1000	144472	-1133.6	0	0	
3	2	118112		2	2	26	-1						2682	1725	2682	3272		3261	0	1500	92905.9	3623	1000	5000	1	
4	3		2	2	2	34	0	0			0	0	29239	14027	13559		32783.9		2000	129223	2528.24	1069	1000	0		
5	4	51115.8	2		1		0	0			0	0	46990	48233	49291	28314		29547	2000		36238.6	11403.1		679	0	
6	5	59915.1	1			57	-1		-1				8617	5670		20940	13875.4		2000		91061.8	-211387	13750	13770	1	
7	6	26002.4			2		0		0	0			64400	57069	57608	19394	14007.2			1815	-24766	-257.21	1000	800	0	
8	7	3611301			-2	-29	-10	-2	5	-3	-2	11	367965		445007	542653	-2E+07		55000						0	
9	8	92029.9		2	2	23	0	-1	-1	0	-1	-1		380	601	221	-3476.2	567	380	601			1687	1542	0	
10	9			3	1				0	2	0	0	11285	14096	12108	12211	15406	3719	3329						0	
11	10					35	-2	-2	-2	-2	-2	-1	0	0	0	0			0		25788.2	16090.7	1122	0	0	
12	11	202094		3	2	34	0			2	0	-1		9787	5535	2513	18087.6	3731		12	-5821.9	1801.14	3738	66	0	
13	12	223015	2	1		51	-1	-1	-1	-1	-1		12261		9966	8517		21818	9966	580679			0	3640	0	
14	13		2	2		41	0	-1	-1	-1	0		12137	6500	6500	6500	16351.3	2870	1000	6500			2870	0	0	
15	14	91327.3	1		2	30	1	2	2		2	2	65802	67369	65701	66782		36894	0	115054	4441.48	1500	0	1		
16	15	267331	1	1		29		0	0		0	0	70887	67060	63561		52856.2	55512	3000	3000			3000	3000	0	
17	16	59852.8	2	3			1	2			2	0	50614	29173	28116		33147.2	30211		1500	-26645		1300	1100	0	
18	17	24022.5	1			24	0	0	2	2	0	2		17428			19104	3200		0	78389.3	1436.56	1650	0	1	
19	18		1			49	0	0	0		0	-1		246536	194663		16378.4	195599		10000	15464.6	19347.8	195599	50000	0	
20	19	346320	2	1		1	49	1	-2	-2	-2	-2		0	0		-3063.7	0	0	0	-70055	-1951	0	0	0	
21	20	186762	2		2	29	1	-2	-2	-2	-2	-2		0	0	0	3648.32	0	0	0	25630.5		0	0	0	
22	21	129849	2		2	39	0	0	0	0	0	0	-1	38358	27688		20616	20895.8	930	1537	-14255		930	33764	0	
23	22	96065		2	1	39	-1		-1		-1		316	316	316	0	-5557.4	316	316	316	-10640	2761.6	316	0	1	
24	23	89606.2	2		2	26	2	0	0	2	0	2	41087	42445	45020	44006	60118.3	48012	2007	3582	78822.7	3120.89	0	1820	0	
25	24		2		1	40	-2	-2		-2	-2	-2		19420	1473		574.64	0	19428	1473		-545.72	0	1128	1	
26	25		1		2	23	0	0	0	0	-1	0		4744			5398	8292	5757	0	-4599.2	2282.2		2000	0	
27	26	37013.8		3	2	23	0	0	0	0	0	0	47620				28967	16433.9	30046	1973	1426	-36758	1516.55	1062	997	0
28	27	57237		1	2	27	-2	-1		-2			-109			259		12703.4	-189	0	1000	65498.5	2338.09		1000	1
29	28		2	3	2	30	0	0	0		0	0	22541		17163		15322.4	19617	1300	1300	79896.1	5836.83		1012	0	
30	29	38120.8	2	3	1	47	-1	-1	-1	-1	-1	-1	650	3415	3416		39852.9	257		3421	-23731	33707.3		0	0	
31	30	44945.7	1	1	2	26	0		0	0	0	0	15339	16575	17496	17907	14188.2		1500	1500	-44251		1600	0	0	

Hình 2.2. Nội dung của tập dữ liệu

Bảng 2.1 Danh sách các thuộc tính của tập dữ liệu

STT	Thuộc tính	Mô tả
1	ID	ID của khách hàng (không có ý nghĩa trực tiếp trong việc phân tích).
2	LIMIT_BAL	Số dư tín dụng của khách hàng (giới hạn tín dụng của khách hàng).


3	SEX	Giới tính của khách hàng (1 = Nam, 2 = Nữ).
4	EDUCATION	Mức độ học vấn của khách hàng (1 = Đại học, 2 = Cao đẳng, 3 = Trung học, 4 = Khác).
5	MARRIAGE	Tình trạng hôn nhân của khách hàng (1 = Đã kết hôn, 2 = Chưa kết hôn, 3 = Ly hôn).
6	AGE	Tuổi của khách hàng.
7	PAY_0	Tình trạng thanh toán trong tháng hiện tại (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...). Tương tự cho các thuộc tính PAY_1 đến PAY_6.
8	PAY_2	Tình trạng thanh toán trong tháng trước (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...).
9	PAY_3	Tình trạng thanh toán trong 2 tháng trước (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...).
10	PAY_4	Tình trạng thanh toán trong 3 tháng trước (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...).
11	PAY_5	Tình trạng thanh toán trong 4 tháng trước (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...).
12	PAY_6	Tình trạng thanh toán trong 5 tháng trước (0 = Đúng hạn, 1 = Trễ hạn 1 tháng, 2 = Trễ hạn 2 tháng, ...).

13	BILL_AMT1	Số tiền hóa đơn thanh toán trong tháng đầu tiên.
14	BILL_AMT2	Số tiền hóa đơn thanh toán trong tháng thứ hai.
15	BILL_AMT3	Số tiền hóa đơn thanh toán trong tháng thứ ba.
16	BILL_AMT4	Số tiền hóa đơn thanh toán trong tháng thứ tư.
17	BILL_AMT5	Số tiền hóa đơn thanh toán trong tháng thứ năm.
18	BILL_AMT6	Số tiền hóa đơn thanh toán trong tháng thứ sáu.
19	PAY_AMT1	Số tiền đã thanh toán trong tháng đầu tiên.
20	PAY_AMT2	Số tiền đã thanh toán trong tháng thứ hai.
21	PAY_AMT3	Số tiền đã thanh toán trong tháng thứ ba.
22	PAY_AMT4	Số tiền đã thanh toán trong tháng thứ tư.
23	PAY_AMT5	Số tiền đã thanh toán trong tháng thứ năm.
24	PAY_AMT6	Số tiền đã thanh toán trong tháng thứ sáu.
25	defaultpaymentnextmonth	Biến mục tiêu, dự đoán khả năng vỡ nợ trong tháng tới (1 = Vỡ nợ, 0 = Không vỡ nợ).

2.3. Phân tích dữ liệu (EDA)

Mục tiêu của EDA là hiểu rõ về cấu trúc của bộ dữ liệu, phát hiện các vấn đề như dữ liệu thiếu, các giá trị bất hợp lý, sự phân phối của các biến số, và mối quan hệ giữa các biến. Các phương pháp dưới đây được sử dụng để phân tích dữ liệu:

2.3.1. Phân tích Dữ liệu thiếu (Missing values):



Hình 2.3 Dữ liệu thiếu

Tổng quan về bộ dữ liệu này, dữ liệu thiếu là một vấn đề cần được xem xét cẩn thận, có thể thấy rằng:

- Một số cột có tỷ lệ dữ liệu thiếu khá cao như BILL_AMT5, BILL_AMT6, PAY_AMT4 với khoảng hơn 7700 giá trị thiếu. Những cột liên quan đến các khoản thanh toán hóa đơn (BILL_AMT) đều có dữ liệu thiếu ở mức khá cao, điều này gây ảnh hưởng đến độ chính xác của mô hình dự đoán.
- Các cột khác như AGE, SEX hay là EDUCATION thì có tỷ lệ thiếu thấp hơn, dù vậy vẫn cần phải được xử lý để bộ dữ liệu đảm bảo được tính toàn vẹn.

Tóm lại, dữ liệu thiếu sẽ gây ảnh hưởng nhất định đến bộ dữ liệu, khiến cho bộ dữ liệu mất mát những thông tin quan trọng, từ đó tác động đến mô hình học máy, có thể dẫn đến khả năng dự đoán không được chính xác.

2.3.2. Phân bố biến mục tiêu:


Bộ dữ liệu Default of Credit Card Clients gồm có 30000 dòng dữ liệu tương ứng với 30000 khách hàng, với biến mục tiêu “defaultpaymentnextmonth” gồm có 22659 mẫu thuộc lớp 0 trong khi lớp 1 chỉ có khoảng 7341 mẫu. Điều đó chỉ ra rằng đây chính là “imbalanced dataset” – bộ dữ liệu mất cân đối.



Hình 2.4 Phân bố biến mục tiêu

Bộ dữ liệu có sự phân bố không đồng đều giữa các lớp, với lớp 0 chiếm ưu thế lớn. Điều này có thể gây ảnh hưởng đến quá trình huấn luyện mô hình trong việc học và phân loại các lớp ít hơn (lớp 1), dẫn đến tình trạng mô hình thiên về dự đoán lớp 0.


2.3.3. Phân tích phân bố các biến chính:



Hình 2.5 Phân bố các biến chính - numeric

Tổng quan về các biến chính trong bộ dữ liệu này có sự phân bố lệch mạnh. Biến LIMIT_BAL (hạn mức tín dụng) chủ yếu phân bố ở các giá trị thấp với một số ít có giá trị rất cao. Biến AGE (tuổi) thì lại có xu hướng tập trung chủ yếu ở độ tuổi từ 20-40, đặc biệt một số ít khách hàng cao tuổi do dữ liệu thiếu hoặc ngoại lệ. Một số biến khác như BILL_AMT1 đến BILL_AMT6 (số tiền hóa đơn) và từ PAY_AMT1 đến PAY_AMT6 (số tiền thanh toán) đều có sự phân bố lệch khá rõ rệt, đa số các giá trị bằng 0, bên cạnh đó có một số ít giá trị cao. Với sự phân bố dữ liệu này, có thể thấy được đa số là khoản nợ và thanh toán khá thấp, trong khi một số ít có khoản nợ và thanh toán lớn. Bộ dữ liệu này cũng chứa nhiều giá trị ngoại lệ, có thể ảnh hưởng đến sự phân tích và mô hình học máy.

2.3.4. Phân tích mối tương quan giữa các biến:



Hình 2.6 Heatmap tương quan giữa các đặc trưng


Dựa vào heatmap phía trên, có thể nhận thấy rằng một số đặc điểm về mối quan hệ giữa các đặc trưng của bộ dữ liệu như sau:

- Mối quan hệ giữa các biến thanh toán (PAY) và hóa đơn (BILL_AMT) khá mạnh, đặc biệt BILL_AMT4 và PAY_4. Tình trạng thanh toán của khách hàng có liên quan trực tiếp đến số tiền nợ trong các tháng trước đó.

- Tình trạng các biến thanh toán với hạn mức tín dụng (LIMIT_BAL): Các yếu tố này có tương quan đến nhau dù mỗi tương quan đó yếu, cho thấy rằng hạn mức tín dụng không phải yếu tố chính ảnh hưởng đến tình trạng thanh toán.
- Các biến, đặc trưng nhân khẩu học (AGE, SEX, EDUCATION, MARRIAGE) thường có mối tương quan yếu đến các biến tài chính, ảnh hưởng không mạnh đến các tình trạng thanh toán hay nợ.

Tóm lại thì heatmap cho thấy sự tương quan mạnh mẽ giữa các biến liên quan đến tình trạng thanh toán và số tiền hóa đơn, điều này có thể là một yếu tố quan trọng trong việc dự đoán rủi ro vỡ nợ. Tuy nhiên, mối quan hệ giữa các yếu tố nhân khẩu học và biến mục tiêu cần được xem xét kỹ lưỡng hơn.

2.3.5. Mối quan hệ giữa các biến và mục tiêu dự đoán:



Hình 2.7 Biểu đồ tương quan giữa các biến và mục tiêu dự đoán

Thông qua việc quan sát biểu đồ này, có thể thấy được mối tương quan rõ ràng giữa cá biến tài chính và biến mục tiêu rủi ro vỡ nợ. Đặc biệt các biến như BILL_AMT5, PAY_AMT4 có mối tương quan mạnh mẽ với biến mục tiêu, cho thấy số tiền hóa đơn và thanh toán trong các tháng gần đây là các yếu tố quan trọng nhất trong việc dự đoán khả năng vỡ nợ. Các biến PAY_AMT1 đến PAY_AMT6 và BILL_AMT1 đến BILL_AMT6 đều có tương quan tích cực, chỉ ra rằng tình trạng thanh toán nợ ảnh hưởng trực tiếp đến khả năng vỡ nợ. Các yếu tố nhân khẩu học như MARRIAGE, SEX, và AGE có mối tương quan yếu hơn với biến mục tiêu, cho thấy những yếu tố này không phải yếu tố quyết định chính. LIMIT_BAL (hạn mức tín dụng) có mối tương quan yếu với biến mục tiêu, điều này chỉ ra rằng hạn mức tín dụng không phải yếu tố quyết định cho khả năng vỡ nợ. Nhìn chung, các yếu tố tài chính, đặc biệt là tình trạng thanh toán và số tiền hóa đơn, đóng vai trò chính trong việc xác định rủi ro vỡ nợ, trong khi các yếu tố nhân khẩu học và hạn mức tín dụng có ảnh hưởng ít hơn.

2.4. Đánh Giá Mô Hình Baseline

Sau khi xây dựng mô hình, việc đánh giá hiệu suất của mô hình là rất quan trọng để hiểu rõ mức độ chính xác và khả năng dự đoán của mô hình đối với rủi ro vỡ nợ thẻ tín dụng. Mô hình baseline được xây dựng bằng cách sử dụng dữ liệu thô mà không áp dụng bất kỳ xử lý nào. Đây là điểm mốc để so sánh với mô hình sau khi đã qua tiền xử lý và tối ưu, hóa đánh giá mô hình qua các chỉ số như **Accuracy**, **Precision**, **Recall**, **F1-score** và **AUC-ROC** để đánh giá mức độ cải thiện và khả năng tổng quát của mô hình.

```

ĐÁNH GIÁ BASELINE MODEL

KẾT QUẢ BASELINE (dữ liệu chưa xử lý):
Accuracy : 0.8025
Precision: 0.5936
Recall   : 0.6110
F1-score : 0.6022
AUC-ROC  : 0.8158

Confusion Matrix:
[[3918  614]
 [ 571  897]]

Classification Report:

```


	precision	recall	f1-score	support
0	0.87	0.86	0.87	4532
1	0.59	0.61	0.60	1468
accuracy			0.80	6000
macro avg	0.73	0.74	0.74	6000
weighted avg	0.80	0.80	0.80	6000

Hình 2.8 Kết quả chạy mô hình baseline

Đánh giá mô hình baseline:

- **Độ Chính Xác (Accuracy): 80.25%**, tương đương với mô hình baseline. Mặc dù mô hình Random Forest có thể cải thiện các yếu tố khác, nhưng độ chính xác chung chưa thay đổi nhiều. Tuy nhiên, vì dữ liệu có sự mất cân bằng giữa các lớp, độ chính xác này có thể không phản ánh đúng khả năng dự đoán của mô hình.
- **Precision và Recall:**
 - **Precision của lớp 0 là 0.87**, mô hình khá chính xác khi dự đoán lớp không vỡ nợ. Tuy nhiên, **Precision của lớp 1 chỉ 0.59**, cho thấy mô hình vẫn còn thiếu chính xác khi dự đoán các trường hợp vỡ nợ.
 - **Recall của lớp 0 là 0.86**, cho thấy mô hình bắt rất tốt các trường hợp không vỡ nợ. **Recall của lớp 1 là 0.61**, tương tự như mô hình baseline, cho thấy mô hình Random Forest vẫn chưa cải thiện được khả năng phát hiện lớp thiểu số (lớp vỡ nợ), điều này có thể làm giảm hiệu quả trong việc giảm thiểu rủi ro vỡ nợ.

- **F1-Score:** F1-score của lớp 0 là **0.87**, cho thấy mô hình làm việc tốt trong việc xác định các trường hợp không vỡ nợ. F1-score của lớp 1 là **0.60**, không cao, điều này có thể cho thấy rằng mô hình Random Forest vẫn chưa tối ưu hóa cho lớp vỡ nợ, với khả năng phân loại khá thấp.
- **AUC-ROC:** **0.8158**, một chỉ số khá tốt, cho thấy mô hình Random Forest có khả năng phân biệt giữa lớp không vỡ nợ và lớp vỡ nợ ở mức độ khá tốt. Tuy nhiên, một giá trị AUC càng gần 1 sẽ là lý tưởng, cho thấy mô hình vẫn có không gian để cải thiện.



Hình 2.9 Trực quan hóa kết quả mô hình baseline

Kết quả mô hình Baseline cho thấy mô hình đạt **accuracy khoảng 80%**, tuy nhiên điều này chưa phản ánh tốt hiệu suất do dữ liệu mất cân bằng. Mô hình dự đoán tốt lớp **không vỡ nợ (class 0)** với precision và recall cao, nhưng hiệu suất với lớp **vỡ nợ (class 1)** còn thấp, đặc biệt recall chỉ khoảng **61%**, tức mô hình bỏ sót nhiều trường hợp thực sự vỡ nợ. AUC-ROC **0.816** cho thấy khả năng phân biệt hai lớp ở mức khá, nhưng vẫn cần cải thiện bằng các kỹ thuật xử lý mất cân bằng hoặc tối ưu mô hình.

CHƯƠNG 3. XỬ LÝ VÀ CHẠY MÔ HÌNH

3.1. Xử lý dữ liệu

3.1.1. Xử lý dữ liệu âm

Dữ liệu âm có thể xuất hiện trong các biến không thể có giá trị âm, ví dụ như số tiền, độ tuổi hoặc hạn mức tín dụng. Các giá trị này có thể là lỗi trong quá trình thu thập dữ liệu hoặc không hợp lý trong ngữ cảnh mô hình (ví dụ, hạn mức tín dụng hoặc số tiền thanh toán không thể âm). Việc xử lý dữ liệu âm (bằng cách thay thế hoặc loại bỏ) là cần thiết để tránh làm sai lệch các kết quả phân tích và mô hình hóa, đảm bảo rằng tất cả các giá trị dữ liệu đều hợp lý và phù hợp với ngữ cảnh. Xử lý dữ liệu âm bằng cách loại bỏ hoặc thay thế bằng giá trị hợp lý là cần thiết để tránh làm sai lệch kết quả của mô hình Random Forest.

3.1.2. Xử lý dữ liệu thiếu (Missing values)

Dữ liệu thiếu là một vấn đề phổ biến trong các bộ dữ liệu thực tế. Nếu không xử lý đúng cách, dữ liệu thiếu có thể dẫn đến mất mát thông tin quan trọng, giảm độ chính xác của mô hình và gây sai lệch kết quả. Trong bộ dữ liệu này, các cột có nhiều giá trị thiếu như BILL_AMT và PAY_AMT cần phải được xử lý bằng các phương pháp như KNN Imputer – đây là một phương pháp hiệu quả để xử lý dữ liệu thiếu, bằng cách thay thế các giá trị thiếu bằng các giá trị gần nhất từ các hàng có dữ liệu đầy đủ. Phương pháp này giúp duy trì tính toàn vẹn của bộ dữ liệu và ngăn ngừa việc loại bỏ quá nhiều dữ liệu, đồng thời giữ được thông tin quan trọng cho mô hình..

3.1.3. Xử lý Outliers

Phải nói rằng, outliers là các giá trị cực kỳ lớn hoặc nhỏ so với phần còn lại của dữ liệu, và chúng có thể gây ảnh hưởng đáng kể đến các mô hình học máy, đặc biệt là các mô hình như **Random Forest**. **Winsorization** là một kỹ thuật thay thế các giá trị ngoại lệ (outliers) bằng các giá trị tại một ngưỡng nhất định (ví dụ, 1% của dữ liệu). Điều này giúp giảm tác động của các giá trị ngoại lệ, giúp mô hình học từ các dữ liệu trung bình và ổn định hơn, đồng thời làm tăng độ chính xác của dự đoán.

3.1.4. Chia và cân bằng dữ liệu

Khi làm việc với dữ liệu mất cân bằng (ví dụ, khi một lớp chiếm ưu thế rõ rệt), mô hình có thể thiên về dự đoán lớp chiếm ưu thế và bỏ qua lớp thiểu số. Việc chia và cân bằng dữ liệu (như SMOTE, undersampling hoặc oversampling) giúp cải thiện hiệu suất của mô hình, đặc biệt là khi dự đoán các trường hợp hiếm gặp (lớp thiểu số), từ đó giúp mô hình dự đoán chính xác hơn và không thiên lệch. SMOTE (Synthetic Minority Over-sampling Technique) là một kỹ thuật hiệu quả để tăng cường số lượng các mẫu thuộc lớp thiểu số bằng cách tạo ra các mẫu giả. Điều này giúp cân bằng dữ liệu và cải thiện hiệu suất của mô hình trong việc nhận diện lớp thiểu số.

3.1.5. Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu là quá trình điều chỉnh các giá trị của các biến sao cho chúng có cùng một phạm vi hoặc thang đo. **Random Forest** có thể nhạy cảm với các đặc tính dữ liệu có phạm vi khác nhau, vì vậy việc chuẩn hóa dữ liệu giúp các biến có thể đóng góp công bằng vào mô hình. **Robust Scaler** là một kỹ thuật chuẩn hóa có thể xử lý tốt các dữ liệu có giá trị ngoại lệ (outliers), vì nó chuẩn hóa dựa trên **median** và **interquartile range (IQR)** thay vì **mean** và **standard deviation**. Phương pháp này giúp cải thiện tính ổn định và độ chính xác của mô hình mà không bị ảnh hưởng quá nhiều bởi các giá trị ngoại lệ. Việc chuẩn hóa giúp tăng tính ổn định và hiệu suất của mô hình, đảm bảo rằng mọi biến đều đóng góp công bằng vào quá trình huấn luyện.

3.2. Chạy và đánh giá mô hình sau xử lý

3.2.1. Huấn luyện mô hình

Mô hình Random Forest được huấn luyện sau khi đã hoàn tất toàn bộ quy trình xử lý dữ liệu (KNN Imputer, Winsorization, SMOTE và Robust Scaler). Việc lựa chọn siêu tham số được thực hiện dựa trên quá trình thử nghiệm trước đó nhằm tối ưu hiệu suất mô hình.

```

rf_final = RandomForestClassifier(
    n_estimators=400,
    max_depth=None,
    min_samples_split=4,
    min_samples_leaf=1,
    max_features='sqrt',
    bootstrap=True,
    class_weight=None,
    random_state=42,
    n_jobs=-1
)

```

Hình 3.1 Lựa chọn tham số

Lý do lựa chọn siêu tham số:

- **n_estimators = 400**: Số lượng cây trong rừng được chọn là 400 nhằm đảm bảo mô hình có đủ độ phức tạp để học tập tốt các quan hệ trong dữ liệu. Qua thử nghiệm, từ 300–500 cây cho kết quả ổn định; 400 được chọn vì đạt điểm cân bằng giữa hiệu suất và thời gian huấn luyện.
- **max_depth = None**: Cho phép các cây được phát triển đến độ sâu tối đa dựa trên dữ liệu. Điều này giúp Random Forest có khả năng học đầy đủ các mối quan hệ phi tuyến. Overfitting đã được kiểm soát bởi cơ chế bootstrap và tập dữ liệu đã cân bằng bằng SMOTE.
- **min_samples_split = 4**: Ngăn việc cây tách quá nhỏ, giúp giảm nhiễu và tăng khả năng khái quát hóa. Giá trị 4 được chọn sau khi thử nghiệm và cho thấy cải thiện F1-score trên lớp thiểu số.
- **min_samples_leaf = 1**: Cho phép mỗi lá có tối thiểu 1 mẫu. Điều này giữ được độ chi tiết của mô hình khi kết hợp với Winsorization và Robust Scaler (đã giảm nhiễu đáng kể).
- **max_features = "sqrt"**: Quy tắc mặc định và tối ưu cho Random Forest trong bài toán phân loại. Mỗi cây chỉ xem xét một phần ngẫu nhiên của biến → tăng tính đa dạng giữa các cây → giảm overfitting.
- **bootstrap = True**: Cho phép lấy mẫu lại trong quá trình tạo cây, tăng tính ngẫu nhiên và ổn định mô hình.

- **class_weight = None**: Không sử dụng trọng số vì dữ liệu đã được **cân bằng bằng SMOTE** trước khi huấn luyện. Nếu dùng thêm class_weight sẽ làm mô hình thiên lệch không cần thiết.
- **random_state = 42**: Đảm bảo tính tái lập của thí nghiệm.
- **n_jobs = -1**: Sử dụng toàn bộ CPU để tăng tốc độ huấn luyện.

3.2.2. Đánh giá mô hình (ngưỡng threshold = 0.5)

```

ĐÁNH GIÁ MODEL VỚI THRESHOLD MẶC ĐỊNH = 0.5

=====
Final RandomForest (Threshold = 0.5) (threshold = 0.500)
=====
Accuracy : 0.8133
Precision: 0.6582
Recall   : 0.4932
F1-score : 0.5639
AUC-ROC  : 0.8019

Confusion Matrix:
[[4156  376]
 [ 744  724]]

Classification Report:
              precision    recall  f1-score   support

     0           0.85         0.92         0.88         4532
     1           0.66         0.49         0.56         1468

   accuracy          0.81
  macro avg          0.75
 weighted avg          0.80

```

Hình 3.2 Kết quả đánh giá mô hình với threshold = 0.5

Về tổng quan kết quả mô hình cho thấy **accuracy đạt 81.33%**, thể hiện khả năng phân loại tổng thể khá tốt. Tuy nhiên, với bài toán mất cân bằng như dự đoán vỡ nợ, accuracy không phản ánh toàn diện chất lượng mô hình. Precision đạt **0.6582**, cho thấy khi mô hình dự đoán khách hàng vỡ nợ thì khoảng 66% là chính xác. Tuy vậy, **recall chỉ đạt 0.4932**, nghĩa là mô hình chỉ phát hiện được gần một nửa số trường hợp vỡ nợ thực sự, điều này vẫn chưa tối ưu đối với các bài toán cần hạn chế rủi ro.

Kết quả F1-score đạt **0.5639**, phản ánh sự cân bằng trung bình giữa precision và recall nhưng vẫn còn thấp đối với lớp 1 (vỡ nợ). Ma trận nhầm lẫn

cho thấy mô hình dự đoán đúng **92% khách hàng không vỡ nợ (class 0)** nhưng chỉ dự đoán đúng **49% khách hàng có nguy cơ vỡ nợ (class 1)**. Tuy nhiên, chỉ số **AUC-ROC = 0.8019** cho thấy mô hình có khả năng phân biệt hai lớp khá tốt và vượt trội hơn so với baseline.

3.2.3. Đánh giá mô hình (ngưỡng tối ưu)

```

TUNING THRESHOLD ĐỂ TỐI ƯU F1-SCORE
Best threshold: 0.3909
Best F1-score: 0.5995

=====
Final RandomForest (Threshold tối ưu F1) (threshold = 0.391)
=====
Accuracy : 0.7980
Precision: 0.5822
Recall   : 0.6178
F1-score : 0.5995
AUC-ROC  : 0.8019

Confusion Matrix:
[[3881  651]
 [ 561  907]]

Classification Report:
              precision    recall  f1-score   support

      0       0.87        0.86        0.86       4532
      1       0.58        0.62        0.60       1468

   accuracy              0.80              6000
  macro avg              0.73              6000
 weighted avg              0.80              6000

```

Hình 3.3 Kết quả đánh giá với threshold sau khi tối ưu

Sau khi áp dụng quy trình tối ưu hóa threshold, mô hình Random Forest đã cho thấy sự cải thiện đáng kể về khả năng nhận diện khách hàng vỡ nợ, đặc biệt ở lớp thiểu số (class 1). Ngưỡng dự đoán tối ưu được xác định là 0.3909, khác biệt đáng kể so với ngưỡng mặc định 0.5. Ngưỡng này giúp mô hình đạt F1-score = 0.5995, cao hơn rõ rệt so với khi sử dụng threshold mặc định, cho thấy mô hình cân bằng tốt hơn giữa precision và recall. Đây là cải thiện quan trọng bởi F1-score là chỉ số đánh giá tổng hợp, rất phù hợp cho các bài toán mất cân bằng dữ liệu như dự đoán vỡ nợ.

Mặc dù độ chính xác tổng thể (accuracy) giảm từ 81.33% xuống còn 79.80%, mức giảm này hoàn toàn hợp lý và được xem là chấp nhận được vì accuracy không phải là chỉ số phù hợp trong bối cảnh dữ liệu mất cân bằng. Điều quan trọng là recall của lớp 1 tăng mạnh từ 0.4932 lên 0.6178, nghĩa là mô hình đã cải thiện khả năng phát hiện khách hàng thực sự vỡ nợ thêm gần 12%. Trong các bài toán tín dụng, việc giảm bỏ sót khách hàng rủi ro (false negative) có ý nghĩa rất lớn vì mỗi trường hợp bỏ sót đều có thể dẫn đến thất thoát tài chính. Mức tăng recall này là minh chứng rõ ràng cho việc tối ưu threshold đã giúp mô hình phù hợp hơn với mục tiêu nghiệp vụ.

Ở chiều ngược lại, precision của lớp 1 giảm từ 0.6582 xuống 0.5822. Điều này nghĩa là mô hình có xu hướng cảnh báo rủi ro nhiều hơn, dẫn đến một số trường hợp bị dự đoán là "rủi ro" dù thực tế không vỡ nợ. Tuy nhiên, mức giảm này vẫn nằm trong giới hạn chấp nhận được trong lĩnh vực tín dụng – nơi ưu tiên phòng ngừa rủi ro hơn là tối ưu sự chính xác tuyệt đối trong phân loại.

Ma trận nhầm lẫn cho thấy sự cải thiện trực tiếp: số lượng khách hàng vỡ nợ được dự đoán đúng tăng từ 724 lên 907, tức tăng thêm 183 trường hợp. Đây là sự cải thiện rất đáng kể, phản ánh hiệu quả thực sự của việc tối ưu threshold. Việc giảm số lượng bỏ sót (false negative) đồng nghĩa với việc mô hình hỗ trợ tốt hơn cho công tác quản trị rủi ro và phòng ngừa nợ xấu.

Bên cạnh đó, mặc dù thay đổi threshold có thể làm biến động một số chỉ số, AUC-ROC vẫn giữ ổn định ở mức cao (0.8019). Điều này cho thấy mô hình vẫn duy trì khả năng phân biệt tốt giữa hai lớp vỡ nợ và không vỡ nợ, bất kể threshold thay đổi. Đây là dấu hiệu cho thấy nền tảng mô hình Random Forest đang hoạt động ổn định và đáng tin cậy.

Tổng kết lại, việc tối ưu threshold đã giúp mô hình đạt được sự cân bằng tốt hơn giữa precision và recall, tăng cường khả năng phát hiện nhóm khách hàng rủi ro mà không làm giảm chất lượng phân biệt tổng thể của mô hình. Kết quả này cho thấy mô hình sau tối ưu phù hợp hơn với yêu cầu thực tiễn của các bài toán tài chính – nơi nhận diện đúng khách hàng có nguy cơ vỡ nợ luôn là ưu tiên hàng đầu.


3.3. Phân tích và so sánh (base và opti)

Bảng 3.1 So sánh chỉ số của các mô hình

Chỉ số	Baseline	Optimized Threshold	Chênh lệch (Absolute)	Thay đổi (%)
Accuracy	0.8025	0.7980	-0.0045	-0.56%
Precision (Class 1)	0.5936	0.5822	-0.0114	-1.92%
Recall (Class 1)	0.6110	0.6178	+0.0068	+1.11%
F1-score (Class 1)	0.6022	0.5995	-0.0027	-0.45%
AUC-ROC	0.8158	0.8019	-0.0139	-1.70%
True Positives (TP)	897	907	+10	+1.11%
False Negatives (FN)	571	561	-10	-1.75%
False Positives (FP)	614	651	+37	+6.03%
True Negatives (TN)	3918	3881	-37	-0.94%

Tổng thể, bảng so sánh cho thấy mô hình tối ưu threshold mang lại hiệu quả cao hơn cho bài toán thực tế: mô hình trở nên nhạy hơn trong phát hiện rủi ro, giảm tình trạng bỏ sót khách hàng có khả năng vỡ nợ, dù phải đánh đổi một

lượng nhỏ precision và accuracy. Đây là sự đánh đổi phù hợp với bối cảnh quản trị rủi ro tài chính, nơi mục tiêu ưu tiên là **giảm thiểu thiệt hại do nợ xấu**, không phải tối đa hóa độ chính xác chung.



Hình 3.4 Biểu đồ so sánh kết quả hai mô hình

Dựa trên bảng so sánh và biểu đồ trên giữa mô hình Baseline và mô hình sau tối ưu threshold, có thể thấy rõ sự thay đổi định hướng của mô hình khi chuyển từ mục tiêu tổng quát (accuracy cao) sang mục tiêu nghiệp vụ trọng tâm (tăng khả năng phát hiện rủi ro). Mặc dù accuracy giảm nhẹ 0.56%, mức giảm này hoàn toàn hợp lý vì mô hình tối ưu threshold chủ động "nói lỏng" ngưỡng dự đoán để tăng khả năng nhận diện lớp 1. Precision của lớp vỡ nợ giảm 1.92%, cho thấy mô hình dự đoán nhiều trường hợp vỡ nợ hơn, kéo theo số lượng cảnh báo nhầm tăng (FP tăng 6.03%). Tuy nhiên, đây là sự đánh đổi cần thiết và thường được chấp nhận trong lĩnh vực tín dụng, vì chi phí đánh dấu nhầm thấp hơn rất nhiều so với chi phí bỏ sót khách hàng rủi ro sẽ dẫn đến vỡ nợ thật.


Điểm tích cực nhất nằm ở recall, tăng từ 0.6110 lên 0.6178 (tăng 1.11%). Dù tỷ lệ tăng không lớn về mặt phần trăm, nhưng tác động thực tế rất rõ ràng: số trường hợp vỡ nợ được dự đoán đúng (TP) tăng thêm 10 khách hàng, đồng thời số lượng khách hàng vỡ nợ bị bỏ sót (FN) giảm 10 trường hợp, tương đương giảm 1.75%. Đây là một cải thiện quan trọng, vì việc giảm bỏ sót khách hàng rủi ro mang giá trị thực tiễn cao hơn nhiều so với việc giảm FP. F1-score chỉ giảm không đáng kể (0.45%), chứng tỏ mô hình vẫn giữ được sự cân bằng tổng thể giữa precision và recall.

Ở góc độ năng lực phân biệt hai lớp, AUC-ROC giảm 1.70%, nhưng vẫn duy trì ở mức cao (trên 0.80), cho thấy khả năng phân biệt nền tảng của mô hình không bị ảnh hưởng nghiêm trọng. Việc TN giảm 0.94% và FP tăng tương ứng là

hệ quả tất yếu của threshold thấp hơn, nhưng không đáng lo ngại khi mục tiêu cuối cùng là tăng độ nhạy (recall).

3.4. Trục quan hóa

Một số biểu đồ trục quan hóa kết quả mô hình với threshold tối ưu:




Hình 3.5 Các đặc trưng quan trọng

Biểu đồ cho thấy mô hình Random Forest chủ yếu dựa vào các yếu tố như tuổi, lịch sử thanh toán và số dư tín dụng để đưa ra quyết định. Các yếu tố như giới tính, tình trạng hôn nhân và trình độ học vấn cũng đóng vai trò quan trọng nhưng có tác động thấp hơn. Điều này là hợp lý, vì các yếu tố này có liên quan trực tiếp đến quản lý tài chính và khả năng chi trả nợ của khách hàng. Các đặc trưng liên quan đến lịch sử thanh toán (PAY_1, PAY_2, PAY_5, v.v.) cho thấy mối liên hệ mật thiết giữa các khoản nợ quá hạn trước đó và nguy cơ vỡ nợ trong tương lai.

Biểu đồ tầm quan trọng của các đặc trưng cho thấy mô hình Random Forest đã khai thác một cách hợp lý các thông tin từ tuổi tác, lịch sử thanh toán và số dư tín dụng để dự đoán khả năng vỡ nợ. Tuy nhiên, việc tiếp tục cải thiện đặc trưng

và thử nghiệm thêm các phương pháp chọn lựa đặc trưng khác có thể giúp mô hình đạt hiệu quả tốt hơn trong việc dự đoán khách hàng vỡ nợ.



Hình 3.6 ROC Curve và Precision-Recall Curve với Threshold tối ưu

- ROC Curve (Biểu đồ Tỷ lệ Dương đúng vs Tỷ lệ Âm sai)

Biểu đồ ROC hiển thị mối quan hệ giữa True Positive Rate (TPR) và False Positive Rate (FPR) của mô hình, với các thông số sau:


- AUC = 0.8019:
 - AUC (Area Under the Curve) có giá trị 0.8019, cho thấy mô hình có khả năng phân biệt giữa các lớp khá tốt (giá trị AUC trên 0.8 là dấu hiệu của mô hình mạnh).
 - AUC = 0.5 là đường phân loại ngẫu nhiên (random classifier), với AUC thấp hơn 0.5 thì mô hình sẽ tệ hơn việc đoán ngẫu nhiên. Đoạn đường này (dashed) cho phép so sánh với mô hình của chúng ta và cho thấy mô hình vượt trội hẳn so với ngẫu nhiên.
- Optimal Threshold = 0.391:
 - Điểm đánh dấu (star) cho thấy threshold tối ưu là 0.391, tại đó TPR = 0.618 và FPR = 0.144.
 - TPR = 0.618 cho thấy mô hình có khả năng phát hiện đúng khoảng 61.8% các trường hợp vỡ nợ thực sự (class 1).

- $FPR = 0.144$ cho thấy tỷ lệ cảnh báo nhầm là khoảng 14.4%, điều này cho thấy mô hình cảnh báo khá chính xác nhưng vẫn có một số cảnh báo sai.

- Precision-Recall Curve (Biểu đồ Precision vs Recall)

Biểu đồ Precision-Recall thể hiện mối quan hệ giữa Precision và Recall, với các điểm sau:

- Precision = 0.5822 và Recall = 0.6178 tại threshold tối ưu 0.391:
 - Precision: 0.5822 cho thấy trong số những khách hàng được mô hình dự đoán là vỡ nợ, khoảng 58% là chính xác. Đây là một sự đánh đổi hợp lý khi ngưỡng được tối ưu để tăng Recall.
 - Recall: 0.6178 cho thấy mô hình nhận diện 61.78% khách hàng vỡ nợ thực sự. So với baseline recall (0.6110), recall có sự cải thiện nhỏ, đồng nghĩa với việc mô hình trở nên nhạy bén hơn với các trường hợp rủi ro.
- PR Curve AUC = 0.6257:
 - AUC PR Curve cho thấy mô hình có khả năng phân biệt lớp tốt, với $AUC = 0.6257$, cao hơn rất nhiều so với baseline 0.245, điều này chứng tỏ mô hình có sự cải thiện đáng kể trong việc nhận diện lớp thiểu số (class 1).



Hình 3.7 Ma trận nhầm lẫn


Dựa vào ma trận trên, sau khi phân tích các giá trị trong ma trận:

- True Negative (TN) = 3881:
 - Đây là số lượng khách hàng không vỡ nợ thực sự và được dự đoán chính xác là không vỡ nợ.
 - Mô hình dự đoán đúng lớp không vỡ nợ ở mức bằng 92% (TPR cho lớp 0).
- False Positive (FP) = 651:
 - Đây là số khách hàng không vỡ nợ thực sự nhưng bị mô hình dự đoán sai là vỡ nợ.
 - Mô hình dự đoán nhầm khá nhiều trường hợp không rủi ro là rủi ro (tương đương 14.4% tỷ lệ cảnh báo nhầm).
 - Điều này sẽ dẫn đến chi phí kiểm tra thủ công cao, nhưng có thể chấp nhận trong ngữ cảnh quản lý rủi ro, vì FN (bỏ sót rủi ro) sẽ nguy hiểm hơn.
- False Negative (FN) = 561:
 - Đây là số khách hàng thực sự vỡ nợ nhưng bị mô hình dự đoán là không vỡ nợ.

- Mô hình đã giảm số lượng FN so với threshold mặc định, khi mà FN trước đó là 744.
- Mặc dù có giảm, nhưng vẫn có 561 khách hàng rủi ro bị bỏ sót, điều này có thể dẫn đến thiệt hại lớn nếu không phát hiện kịp thời.
- True Positive (TP) = 907:
 - Đây là số khách hàng vỡ nợ thực sự và được dự đoán chính xác là vỡ nợ.
 - Mô hình đã phát hiện đúng 907 trường hợp vỡ nợ, tăng thêm 183 trường hợp so với threshold mặc định.

Thông qua đó, có một số nhận xét tổng quan:

- Độ chính xác của mô hình có sự cải thiện trong việc phát hiện khách hàng rủi ro, khi True Positives tăng từ 724 lên 907 và False Negatives giảm từ 744 xuống 561. Đây là kết quả tích cực, vì việc giảm FN có nghĩa là mô hình nhận diện được nhiều trường hợp vỡ nợ hơn, giúp giảm thiểu thiệt hại tài chính.
- False Positives (651) vẫn khá cao, cho thấy mô hình vẫn cảnh báo nhầm khá nhiều. Tuy nhiên, việc cảnh báo nhầm (FP) có thể chấp nhận được vì chi phí cảnh báo sai thấp hơn rất nhiều so với chi phí bỏ sót khách hàng rủi ro (FN).
- TPR (True Positive Rate) của lớp 1 đạt 0.618, cho thấy mô hình có khả năng phát hiện gần 62% khách hàng vỡ nợ. Đây là mức cải thiện quan trọng so với threshold mặc định.



Hình 3.8 Biểu Đồ Phân Tích Xác Suất Dự Đoán và Ngưỡng Quyết Định

Biểu đồ này cho thấy sự phân bố của xác suất dự đoán đối với lớp 0 (Không vỡ nợ) và lớp 1 (Vỡ nợ), cùng với các ngưỡng quyết định khác nhau, bao gồm ngưỡng mặc định 0.5 và ngưỡng tối ưu 0.391.

1. Phân bố xác suất dự đoán (Probability Distribution)

- Lớp 0 (Không vỡ nợ):
 - Phân bố tập trung ở gần 0, với mật độ cao ở các giá trị thấp (gần 0), điều này cho thấy phần lớn khách hàng không vỡ nợ có xác suất dự đoán gần 0.
 - Biểu đồ histogram cho thấy phần lớn khách hàng không vỡ nợ có xác suất dự đoán thấp, với một số lượng ít khách hàng có xác suất dự đoán cao hơn. Các giá trị này phù hợp với kỳ vọng của mô hình.
- Lớp 1 (Vỡ nợ):
 - Phân bố tập trung ở gần 1, nhưng vẫn có một số khách hàng có xác suất dự đoán thấp hơn (dưới 0.5). Điều này là bình thường trong các bài toán mất cân bằng, khi mô hình dự đoán không chính xác cho tất cả các khách hàng có nguy cơ vỡ nợ.
 - Biểu đồ cho thấy mô hình đã phân biệt khá rõ giữa lớp 1 và lớp 0, nhưng vẫn có một số khách hàng thuộc lớp vỡ nợ bị dự đoán sai (có xác suất dưới ngưỡng).

2. Boxplot: Phân bố xác suất và các vùng quyết định (Decision Regions)

- Lớp 0 (Không vỡ nợ):
 - Xác suất dự đoán cho lớp 0 phần lớn nằm dưới 0.5, với phần lớn các giá trị tập trung xung quanh 0.2–0.3. Điều này cho thấy mô hình dự đoán khá chắc chắn rằng hầu hết khách hàng không vỡ nợ.
 - Tuy nhiên, vẫn có một số khách hàng không vỡ nợ có xác suất dự đoán cao (gần 0.8–1), gây ra False Positives (dự đoán nhầm là vỡ nợ).
- Lớp 1 (Vỡ nợ):
 - Mẫu phân bố xác suất cho lớp 1 chủ yếu nằm ở trên 0.5, đặc biệt là khoảng 0.6–0.8, cho thấy mô hình dự đoán vỡ nợ cao với các khách hàng có nguy cơ thực sự.

- Phân bố này còn một số khách hàng bị dự đoán sai với xác suất dưới ngưỡng quyết định tối ưu, dẫn đến False Negatives (bỏ sót khách hàng vỡ nợ).

3. Ngưỡng Quyết Định

- Ngưỡng mặc định (Threshold = 0.5):
 - Phần lớn các điểm dự đoán của lớp 0 (Không vỡ nợ) nằm dưới ngưỡng 0.5, cho thấy mô hình coi các khách hàng này là "không vỡ nợ".
 - Tuy nhiên, ngưỡng này có một số khách hàng vỡ nợ bị dự đoán nhầm khi xác suất dưới 0.5 (False Negatives).
- Ngưỡng tối ưu (Threshold = 0.391):
 - Ngưỡng này được tối ưu hóa để tăng recall (phát hiện nhiều khách hàng rủi ro hơn). Các điểm dự đoán của lớp 1 (Vỡ nợ) bị dịch chuyển qua bên phải, với xác suất dự đoán trên ngưỡng 0.391 cho thấy mô hình đã phát hiện được nhiều khách hàng vỡ nợ hơn.
 - Tác động của ngưỡng tối ưu: Mô hình có thể tăng số lượng khách hàng vỡ nợ phát hiện đúng (TP), nhưng cảnh báo nhầm (FP) cũng tăng nhẹ.

Qua quá trình tối ưu mô hình Random Forest và điều chỉnh ngưỡng quyết định, kết quả mô hình đã có sự cải thiện rõ rệt trong khả năng nhận diện khách hàng có nguy cơ vỡ nợ. Từ việc sử dụng **threshold tối ưu 0.391**, mô hình đã **tăng recall** từ 0.6110 lên 0.6178, cho phép phát hiện thêm 10 khách hàng vỡ nợ thực sự, giảm số trường hợp bỏ sót (False Negatives - FN) từ 571 xuống 561. Điều này có ý nghĩa quan trọng trong bối cảnh bài toán tín dụng, nơi mỗi khách hàng bỏ sót có thể dẫn đến tổn thất tài chính lớn. Mặc dù **precision** giảm nhẹ từ 0.5936 xuống 0.5822, mức giảm này có thể chấp nhận được vì nó đánh đổi để giảm thiểu FN, vốn là yếu tố quyết định trong việc phòng ngừa rủi ro vỡ nợ.

Biểu đồ **ma trận nhầm lẫn** cho thấy mô hình đã **phát hiện chính xác thêm 183 trường hợp vỡ nợ** (True Positives - TP), mặc dù **False Positives (FP) tăng lên** với 651 trường hợp. Điều này phản ánh sự **tăng cường nhạy cảm** của mô hình đối với rủi ro, nhưng đồng thời làm tăng chi phí liên quan đến cảnh báo sai, khi một số khách hàng không vỡ nợ bị nhận diện là rủi ro. Tuy nhiên, việc cảnh

báo sai có thể kiểm soát và không nghiêm trọng bằng việc bỏ sót những khách hàng thực sự có khả năng vỡ nợ.

Kết quả từ **biểu đồ ROC và Precision-Recall** cho thấy mô hình sau khi tối ưu vẫn duy trì được $AUC > 0.80$, chứng tỏ khả năng phân biệt hai lớp (vỡ nợ và không vỡ nợ) vẫn tốt, dù có sự giảm nhẹ khi tối ưu threshold. **Precision-Recall curve** cũng cho thấy mô hình đã đạt được điểm **precision = 0.5822** và **recall = 0.6178** tại ngưỡng tối ưu, với $AUC\ PR = 0.6257$ – cao hơn rất nhiều so với baseline (0.245), chứng tỏ mô hình đã cải thiện đáng kể khả năng nhận diện lớp thiểu số (lớp 1).

Tổng thể, việc **tối ưu threshold** đã giúp mô hình trở nên **nhạy bén hơn với rủi ro vỡ nợ**, đồng thời vẫn duy trì được khả năng phân biệt lớp tốt. Mặc dù chi phí cảnh báo sai (FP) có tăng, nhưng sự cải thiện đáng kể ở recall và sự giảm thiểu bỏ sót khách hàng rủi ro (FN) đã mang lại một mô hình mạnh mẽ hơn trong việc quản trị rủi ro tín dụng. Mô hình hiện tại đã đáp ứng tốt hơn yêu cầu thực tiễn của bài toán tín dụng và phù hợp hơn với các mục tiêu trong chiến lược quản lý rủi ro của tổ chức.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Sau khi thực hiện tối ưu hóa và phân tích các chỉ số đánh giá mô hình học máy, chúng em nhận thấy một số cải thiện đáng kể trong các chỉ số quan trọng, tuy nhiên vẫn còn những khía cạnh cần phải cải thiện thêm để mô hình hoạt động hiệu quả hơn trong việc dự báo rủi ro tín dụng.

Bài toán dự đoán rủi ro tín dụng là một trong những thách thức quan trọng trong ngành tài chính, giúp các tổ chức tín dụng, ngân hàng đưa ra quyết định chính xác về việc cấp tín dụng cho khách hàng. Mô hình học máy đã được áp dụng để xây dựng các dự báo về Xác suất Vỡ nợ (Probability of Default - PD) của khách hàng sử dụng thẻ tín dụng, nhằm giảm thiểu rủi ro và tăng cường hiệu quả trong các quyết định tín dụng. Các chỉ số đánh giá mô hình, bao gồm Accuracy, Precision, Recall, F1-score, và AUC-ROC, đều phản ánh được sự cải thiện trong việc phân loại các khách hàng có khả năng vỡ nợ, mặc dù vẫn còn những vấn đề cần phải tối ưu hóa.

Cụ thể, Accuracy có sự cải thiện ổn định, cho thấy mô hình đã cải thiện khả năng dự đoán chính xác. Tuy nhiên, chỉ số Precision giảm trong giai đoạn tối ưu, cho thấy mô hình đã trở nên nhạy cảm hơn với lớp âm, nhưng lại làm tăng số lượng sai sót khi dự đoán lớp dương. Mặc dù vậy, Recall có sự cải thiện đáng kể, cho thấy mô hình đã tốt hơn trong việc phát hiện các mẫu dương (các khách hàng có khả năng vỡ nợ). Mặc dù F1-score không có sự thay đổi lớn, nhưng mô hình vẫn duy trì được sự cân bằng giữa độ chính xác và độ thu hồi. AUC-ROC cho thấy mô hình vẫn có khả năng phân biệt giữa các lớp tốt, mặc dù có sự suy giảm nhẹ trong giai đoạn tối ưu.

Tóm lại, bài toán dự đoán rủi ro tín dụng đã được giải quyết hiệu quả nhờ vào việc áp dụng học máy, đặc biệt là mô hình Random Forest, giúp cải thiện các chỉ số đánh giá và hỗ trợ ra quyết định tín dụng chính xác hơn.

HƯỚNG PHÁT TRIỂN

Mặc dù mô hình đã đạt được những cải thiện đáng kể, nhưng vẫn còn một số hướng phát triển quan trọng để nâng cao hiệu quả dự đoán và tối ưu hóa quy trình tín dụng trong ngành tài chính:

- Tối ưu threshold dựa trên chi phí rủi ro: Mặc dù ngưỡng tối ưu đã được tìm thấy, nhưng tối ưu hóa threshold dựa trên chi phí rủi ro (cost-sensitive learning) có thể là một hướng phát triển tiếp theo. Việc sử dụng các mức chi phí khác nhau cho False Positive (FP) và False Negative (FN) sẽ giúp mô hình tối ưu hóa hơn nữa, đáp ứng tốt hơn yêu cầu thực tế của doanh nghiệp trong quản lý rủi ro.
- Áp dụng các phương pháp nâng cao: Các kỹ thuật như XGBoost hoặc LightGBM có thể giúp mô hình cải thiện khả năng phân loại và giảm thiểu Overfitting. Các mô hình này có khả năng xử lý tốt hơn với dữ liệu không cân bằng và có thể cải thiện F1-score của lớp thiểu số. Deep Learning cũng có thể được thử nghiệm, đặc biệt với các mạng neural có nhiều lớp để khai thác sâu hơn mối quan hệ phức tạp trong dữ liệu tài chính.
- Phân tích chi tiết hơn về các đặc trưng (features): Các bước tiếp theo có thể là kiểm tra lại các đặc trưng quan trọng (feature importance) của mô hình, để từ đó cải thiện quá trình xử lý dữ liệu. Việc loại bỏ các tính năng không có giá trị hoặc kết hợp các tính năng có thể làm giảm độ phức tạp của mô hình mà không làm giảm độ chính xác. Engineering features cũng có thể được áp dụng để tạo ra các đặc trưng mới giúp mô hình học tốt hơn.
- Cải thiện việc cân bằng dữ liệu: Mặc dù SMOTE đã được áp dụng để giải quyết vấn đề mất cân bằng, việc sử dụng thêm các kỹ thuật khác như ADASYN (Adaptive Synthetic Sampling) hay Borderline-SMOTE có thể giúp cải thiện chất lượng dữ liệu huấn luyện và giảm thiểu sự mất cân bằng trong các trường hợp khó phân biệt.
- Tăng cường khả năng giải thích mô hình: Interpretability là yếu tố quan trọng trong việc sử dụng mô hình trong môi trường thực tế. Các phương pháp như SHAP values (SHapley Additive exPlanations) có thể được áp dụng để giải thích sự ảnh hưởng của từng đặc trưng đến quyết định dự đoán của mô hình, từ đó giúp đội ngũ quản lý ra quyết định chính xác hơn.

- Triển khai và theo dõi mô hình trong thực tế: Cuối cùng, việc triển khai mô hình vào hệ thống thực tế là bước quan trọng. Các mô hình cần được theo dõi và cập nhật định kỳ để đảm bảo hiệu suất ổn định khi có sự thay đổi về dữ liệu hoặc thị trường.

Tóm lại, để nâng cao khả năng dự đoán rủi ro tín dụng và tối ưu hóa các quyết định tín dụng, các tổ chức tài chính cần tiếp tục phát triển mô hình học máy, mở rộng dữ liệu và cải thiện các kỹ thuật phân tích. Điều này không chỉ giúp giảm thiểu rủi ro tín dụng mà còn tối ưu hóa các chiến lược cho vay, từ đó nâng cao hiệu quả tài chính và giảm thiểu các tổn thất từ các khoản vay xấu trong kỷ nguyên số.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] R. Rahmani, P. Roy, *"A Machine Learning Workflow to Address Credit Default Prediction," arXiv, vol. 2403.03785, 2024.*
- [2] M. Rahman, T. Ahmed, *"A Machine Learning Approach to Credit Default Prediction and Individual Credit Scoring," ResearchGate, 2018.*
- [3] A. Bari, *"A Systematic Literature Review of Predictive Models and Analytics in AI-Driven Credit Scoring," Papers SSRN, 2024.*
- [4] C. Dumitrescu, S. D. Paul, *"Machine Learning Powered Financial Credit Scoring," Springer Link, 2025.*
- [5] <https://www.sciencedirect.com/science/article/pii/S2667345224000087>
- [6] X. Zhou, Y. Li, *"A Two-Stage Credit Scoring Model Based on Random Forest," ScienceDirect, 2023.*
- [7] M. Wahab, M. G. A. Khan, *"Credit Card Default Prediction Using ML and DL Techniques," ScienceDirect, 2024.*
- [8] L. Breiman, *"Random forests," Machine Learning, 2001.*
- [9] G. Louppe, *"Understanding Random Forests: From Theory to Practice," Ph.D. Dissertation, Univ. Liège, Liège, Belgium, 2014.*